MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Informe técnico grupal · 20 %

Título del proyecto:	Incumplimiento de plazos en envíos de comercio electrónico
Integrantes:	Marco Álvarez Araya · Ricardo Jaramillo
Dataset:	E-Commerce Shipping Data (Kaggle)
Docente:	Dr. Jean Paul Maidana González
Fecha:	14/10/2026
Repositorio GitHub:	https://github.com/RJaramilloP/estadistica-computacional-Sumativa-1

Índice

1. Preparación y carga de datos 2
2. Análisis exploratorio de datos 3
2.1 Estadística descriptiva 3
2.2 Análisis bivariado 4
2.3 Estructura del archivo y análisis de sensibilidad 4
3. Estimación de parámetros 5
4. Pruebas de hipótesis 6
4.1 Prueba 1: peso medio según el cumplimiento del plazo (t de Welch) 6
4.2 Prueba 2: importancia del producto y cumplimiento (χ^2 de independencia) 6
4.3 Análisis de sensibilidad consolidado 7
5. Informe de avance del proyecto 7
6. Notebook y repositorio GitHub 8
7. Bibliografía 8

1. Preparación y carga de datos

El proyecto utiliza el conjunto *E-Commerce Shipping Data* (Prachi13, s. f.), con 10.999 envíos de una empresa de comercio electrónico y doce variables. La variable de respuesta, *Reached.on.Time_Y.N*, vale 1 cuando el envío llegó fuera de plazo y 0 cuando llegó a tiempo. La Tabla 1 clasifica las variables según su naturaleza y su escala de medición (Stevens, 1946).

Tabla 1. Clasificación de las variables del conjunto de datos.

Variables	Naturaleza	Escala	Rol
ID	Identificador nominal	Nominal	Identificador
Warehouse_block, Mode_of_Shipment, Gender	Cualitativa nominal	Nominal	Explicativa
Customer_care_calls, Prior_purchases	Cuantitativa discreta	Razón	Explicativa
Customer_rating, Product_importance	Cualitativa ordinal	Ordinal	Explicativa
Cost_of_the_Product	Cuantitativa monetaria	Razón	Explicativa
Discount_offered	Cuantitativa	Pendiente de confirmar	Explicativa
Weight_in_gms	Cuantitativa continua, registrada en gramos enteros	Razón	Explicativa
Reached.on.Time_Y.N	Cualitativa nominal binaria	Nominal	Respuesta

Fuente: notebook §1.3 · resultados/tablas/diccionario_variables.csv

La revisión de calidad, sin modificar el archivo original, no encontró faltantes, filas duplicadas ni identificadores repetidos, y todos los valores cumplen los controles de dominio, lo que no demuestra ausencia de errores. Las limitaciones son de documentación: la unidad del descuento no está informada y se desconoce si el descuento, las llamadas y la calificación se registraron antes o después de la entrega (Tabla 2).

Tabla 2. Decisiones de tratamiento de la información.

Situación	Decisión
Valores faltantes (0 en las 12 variables)	No se imputa. Se documenta como insumo de S3, donde la imputación requerirá inducir faltantes de forma controlada.
Filas duplicadas e ID repetidos (0)	No se elimina ningún registro.
Valores altos de Discount_offered (cola derecha hasta 65)	Se conservan: no hay evidencia suficiente para clasificarlos como errores de captura. Se reporta la mediana junto a la media.
Unidad de Discount_offered no documentada	Se analiza en su escala original, sin interpretarla como porcentaje.

Situación	Decisión
Momento de registro de descuento, llamadas y calificación desconocido	Se interpretan como asociaciones, no como causas; se declara el riesgo de que sean posteriores al resultado (fuga de información).
Campo ID	Se excluye como variable explicativa, pero se usa como diagnóstico de la estructura del archivo (§2.3 de este informe).

Fuente: notebook §1.4 · resultados/tablas/tab01_decisiones_tratamiento.csv

2. Análisis exploratorio de datos

2.1 Estadística descriptiva

El 59,67 % de los envíos (6.563) llegó fuera de plazo y el 40,33 % (4.436) a tiempo: el incumplimiento es la categoría mayoritaria. La Tabla 3 resume las variables numéricas con medidas de posición, escala y forma (NIST, s. f.-a, s. f.-b).

Tabla 3. Medidas descriptivas de las variables numéricas (n = 10.999).

Variable	Media	Mediana	Desv. est.	Mín.	Máx.	RIC	Asimetría	Curtosis*
Costo del producto	210,20	214	48,06	96	310	82,0	−0,16	−0,97
Peso (g)	3.634,0	4.149	1.635,4	1.001	7.846	3.210,5	−0,25	−1,45
Llamadas	4,05	4	1,14	2	7	2,0	0,39	−0,31
Compras previas	3,57	3	1,52	2	10	1,0	1,68	4,01
Descuento	13,37	7	16,21	1	65	6,0	1,80	2,00

Fuente: notebook §2.2 · resultados/tablas/tab03_descriptiva_numericas.csv. RIC: rango intercuartílico; *curtosis en exceso (0 en la normal); por sí sola no demuestra normalidad ni el número de modas.

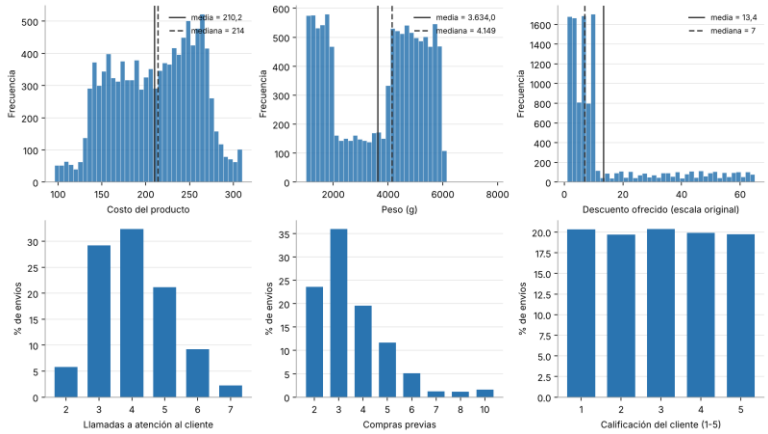


Figura 1. Distribución de las variables numéricas. Arriba: histogramas con media (línea continua) y mediana (discontinua). Abajo: frecuencia relativa de las variables discretas.

Fuente: notebook §2.3, figura 2 · resultados/figuras/fig02_distribucion_numericas.png

El costo es casi simétrico (media 210,20, mediana 214). El peso es **bimodal** (Figura 1): se concentra entre 1.000 y 2.000 g y entre 4.000 y 6.000 g, y su media (3.634 g) cae en la zona de menor densidad y no representa un envío típico; la bimodalidad se ve en el histograma, no en la curtosis. El descuento tiene dos regímenes: la mayoría de los valores está entre 1 y 10 (tercer cuartil y moda iguales a 10) y una meseta baja se extiende hasta 65, por lo que la media (13,37) casi duplica a la mediana (7). La calificación es prácticamente uniforme (cerca del 20 % por valor); esta regularidad no permite determinar si los datos son reales o sintéticos.

Entre las categóricas (Figura 2), el transporte marítimo concentra el 67,8 % de los envíos y el bloque F, el 33,3 %; los bloques A a D reúnen cerca de un sexto cada uno. La importancia es mayoritariamente baja (48,2 %) o media (43,2 %); solo el 8,6 % es alta. Las frecuencias absolutas están en la Tabla 4 del notebook.

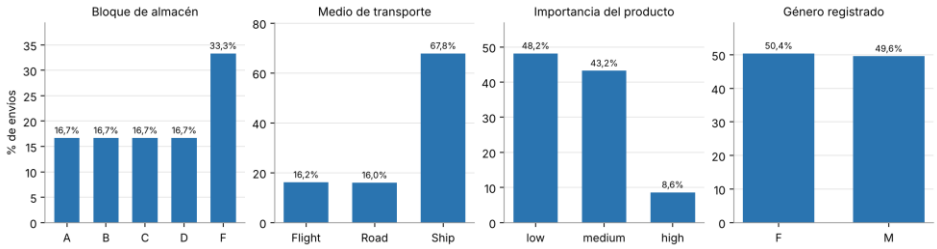


Figura 2. Frecuencia relativa de las variables categóricas.
Fuente: notebook §2.4, figura 3 · resultados/figuras/fig03_distribucion_categoricas.png

2.2 Análisis bivariado

Se usó la correlación de Spearman, adecuada para variables asimétricas, bimodales u ordinales. Solo dos variables se asocian de forma apreciable con el retraso: el **descuento** ($\rho = 0{,}335$) y el **peso** ($\rho = -0{,}266$); las demás tienen $|\rho| < 0{,}08$. Entre explicativas, la correlación máxima es $|\rho| = 0{,}32$ (descuento y peso); no hay correlaciones altas por pares, aunque esto no descarta multicolinealidad en un modelo posterior. Por grupos, los envíos fuera de plazo pesan en promedio 3.273 g, frente a 4.169 g, y su descuento medio (18,7) triplica al de los envíos a tiempo (5,5).

La Figura 3 muestra que el porcentaje fuera de plazo se mantiene cerca del global (59,7 %) entre bodegas, medios de transporte, géneros y calificaciones. Destacan la importancia **alta** (65,0 % frente a 59,3 % en baja) y un gradiente descendente con las llamadas (65,2 % con dos y 51,6 % con siete), contraintuitivo, que se revisa en la sección 4.3.

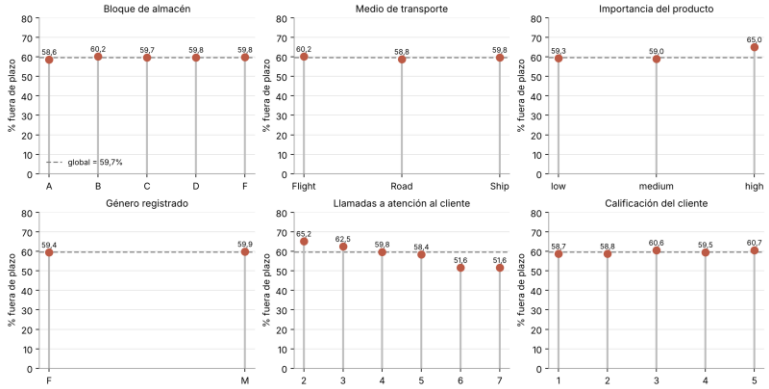


Figura 3. Porcentaje de envíos fuera de plazo por categoría; la línea discontinua indica el porcentaje global.
Fuente: notebook §2.5, figura 5 · resultados/figuras/fig05_tasa_por_categoria.png

2.3 Estructura del archivo y análisis de sensibilidad

Al ordenar los registros por *ID* aparecen **dos regímenes con una frontera abrupta en el ID 3.135** (Tabla 4 y Figura 4). En el bloque inicial, el 100 % de los envíos llegó fuera de plazo y se concentran los descuentos mayores a 10 y los pesos entre 2.000 y 3.999 g. Después del corte, el porcentaje fuera de plazo se estabiliza en torno al 44 % y el descuento nunca supera 10. Los umbrales actúan como reglas deterministas: con descuento mayor a 10 el 100 % de los envíos está fuera de plazo, y con peso entre 2.000 y 3.999 g, el 99,9 %.

Se incorpora un **análisis de sensibilidad** que repite la estimación y las pruebas en el subconjunto ID > 3.135 (n = 7.864), por cuatro razones:

- **Composición.** La existencia de grupos distintos no invalida por sí sola el análisis global, pero se desconoce cómo se conformaron los bloques y si sus proporciones representan a la población; agregarlos puede producir asociaciones aparentes o invertidas (paradoja de Simpson; Simpson, 1951).
- **Plausibilidad.** Un umbral que determina el resultado sin excepciones no es habitual en logística: sugiere un artefacto o, si el descuento compensó el retraso, una variable posterior al resultado (fuga de información).
- **Decisión.** Evita recomendar intervenciones basadas en patrones que dependen de la composición del archivo.
- **Continuidad.** La Sumativa 2 evalúa robustez frente a observaciones influyentes, y en la Sumativa 3 el descuento produciría separación casi perfecta en la regresión logística.

Tabla 4. Comparación entre el bloque inicial y el resto del archivo.

Indicador	ID ≤ 3.135	ID > 3.135
Registros	3.135	7.864
% fuera de plazo	100,0 %	43,6 %
Descuento medio (máximo)	33,1 (65)	5,5 (10)
% con descuento > 10	84,4 %	0,0 %
Peso medio (g)	2.366	4.140
% con peso 2.000–3.999 g	57,0 %	0,04 %

Fuente: notebook §2.6 · resultados/tablas/tab08_comparacion_bloques.csv

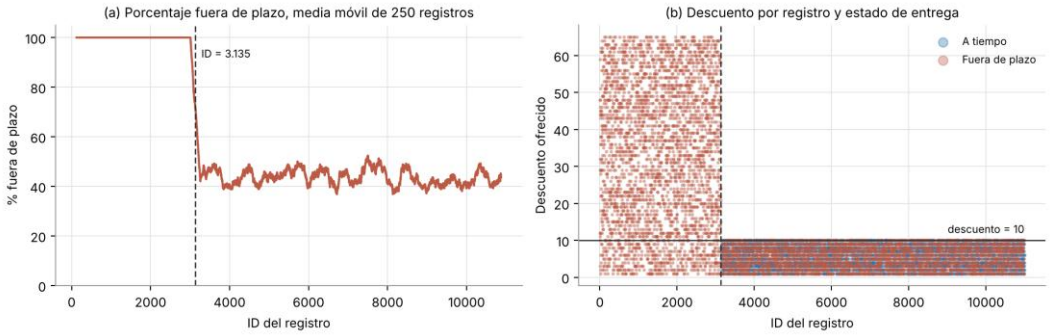


Figura 4. (a) Porcentaje fuera de plazo, media móvil de 250 registros. (b) Descuento por registro y estado de entrega. La línea vertical marca el ID 3.135.

Fuente: notebook §2.6, figura 7 · resultados/figuras/fig07_estructura_por_id.png

Salvaguardas. El análisis principal usa los 10.999 registros y el subconjunto es complementario. El corte se definió tras observar los datos, por lo que las comparaciones son exploratorias; que el último descuento mayor a 10 esté en el ID 3.134 es evidencia descriptiva, no una validación independiente. Al excluir una racha de solo retrasos, la proporción observada baja por construcción y no se estima en el subconjunto, donde además el descuento solo varía entre 1 y 10.

3. Estimación de parámetros

Se estimaron la proporción de envíos fuera de plazo y las medias del costo, el peso y el descuento: el costo representa el valor despachado, y el peso y el descuento son las variables más asociadas con el retraso. Para las medias se usó el intervalo basado en la aproximación normal de gran muestra (Teorema Central del Límite; Wasserman, 2004); el tamaño muestral favorece la aproximación, pero no garantiza independencia ni corrige sesgos de selección:

$$\bar{x} \pm z_{0,975} \cdot s / \sqrt{n}$$

Para la proporción se usó el intervalo de Wald, cuya condición de conteos grandes se cumple porque $n \cdot \hat{p}$ y $n \cdot (1 - \hat{p})$ superan ampliamente 10:

$$\hat{p} \pm z_{0,975} \cdot \sqrt{\hat{p}\,(1 - \hat{p}) / n}$$

Interpretación. El intervalo de Wald para la proporción de envíos fuera de plazo es [58,75 %; 60,59 %]. El 95 % es una propiedad del **procedimiento**: bajo sus supuestos, si se repitiera el muestreo muchas veces, aproximadamente el 95 % de los intervalos así construidos contendría la proporción poblacional. No significa que haya un 95 % de probabilidad de que el parámetro esté en este intervalo ya calculado; lo mismo vale para las medias de la Tabla 5. *Complemento (no evaluado):* el intervalo de Wilson (Wilson, 1927) da [58,75 %; 60,58 %], muy próximo al de Wald, aunque no idéntico.

Tabla 5. Estimación puntual e intervalos de confianza al 95 %.

Parámetro	Estimación	IC 95 %	Método	ID > 3.135: estimación [IC 95 %]
Proporción fuera de plazo	0,5967	[0,5875; 0,6059]	Normal (Wald)	No se estima*
Costo medio	210,20	[209,30; 211,10]	Normal (TCL)	215,86 [214,80; 216,91]
Peso medio (g)	3.634,0	[3.603,5; 3.664,6]	Normal (TCL)	4.139,6 [4.104,7; 4.174,6]
Descuento medio	13,37	[13,07; 13,68]	Normal (TCL)	5,52 [5,46; 5,58]

Fuente: notebook §3 · resultados/tablas/tab10_intervalos_confianza.csv y tab11_sensibilidad_ic.csv. *No se estima: el corte se definió usando la variable respuesta (§2.3).

Limitaciones. (1) Los intervalos son estrechos (semiancho menor al 2,3 % de cada estimación), pero solo cuantifican el error de muestreo y no protegen contra sesgos. (2) La media del peso no describe un envío típico de una distribución bimodal; conviene acompañarla de la mediana (4.149 g). (3) La media del descuento depende de la meseta de valores altos (mediana 7) y su unidad no está documentada. (4) Al excluir el bloque inicial, el descuento medio cae un 58,7 % y el peso medio sube un 13,9 %, sin solapamiento de intervalos. (5) **Origen:** no se documentan la empresa, el período ni el diseño muestral; no puede asegurarse representatividad ni extrapolar los resultados a otras operaciones logísticas.

4. Pruebas de hipótesis

Se adoptó $\alpha = 0{,}05$, que fija en 5 % la tasa nominal de error tipo I de cada contraste (destinar recursos a un factor sin la asociación postulada); no equilibra por sí solo el error tipo II, que depende también del tamaño muestral y del efecto. Como con más de diez mil registros diferencias pequeñas resultan significativas, cada prueba incluye un tamaño del efecto (Wasserstein y Lazar, 2016). La **independencia de las observaciones** se asume en todas las pruebas y no puede verificarse por completo. Los contrastes complementarios y la sensibilidad son exploratorios y sus valores p no se ajustan por multiplicidad.

4.1 Prueba 1: peso medio según el cumplimiento del plazo (t de Welch)

H_0: μ fuera de plazo = μ a tiempo vs. H_1: μ fuera de plazo ≠ μ a tiempo

Supuestos. El peso no es normal en ningún grupo (bimodal; asimetría −0,93 en los envíos a tiempo), pero con 6.563 y 4.436 observaciones el TCL respalda la aproximación para la media. Las desviaciones estándar son casi iguales (1.576 y 1.574 g), pero la prueba de Levene rechaza la igualdad de dispersión ($p < 0{,}001$), sensible a la forma de las distribuciones, y los tamaños son desiguales; por eso se usa la prueba de Welch, que no exige varianzas iguales (Welch, 1947).

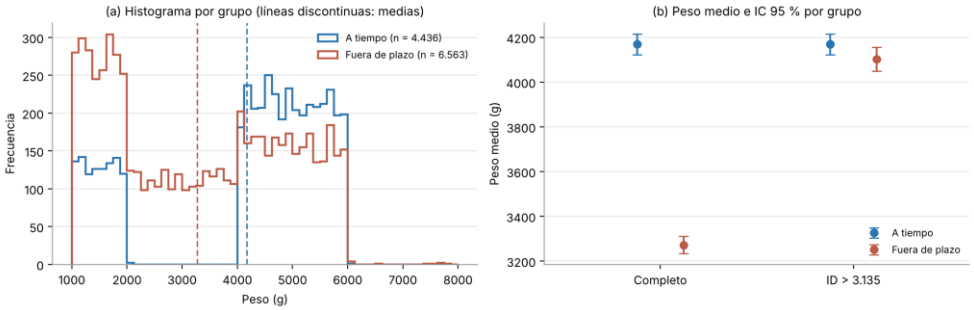


Figura 5. (a) Histograma del peso por grupo; líneas discontinuas: medias. (b) Peso medio e IC 95 % por grupo, en el dataset completo y en ID > 3.135.

Fuente: notebook §4.1, figura 8 · resultados/figuras/fig08_prueba1_peso.png

Resultado. Los envíos fuera de plazo pesan en promedio 896 g menos (IC 95 % [−956; −836] g; $t = -29{,}27$; gl ≈ 9.527; $p < 0{,}001$): **se rechaza H_0**, con un efecto moderado (d de Cohen = −0,57; Cohen, 1988). **Sensibilidad:** en ID > 3.135 la diferencia se atenúa a 67 g (IC 95 % [−137; 4]; $d = -0{,}04$; $p = 0{,}065$) y no se rechaza H_0, lo que no demuestra ausencia de efecto. La Figura 5a lo explica: el grupo a tiempo no tiene envíos entre 2.000 y 3.999 g, tramo del bloque inicial. **Implicancia:** el peso no debería usarse para priorizar despachos.

4.2 Prueba 2: importancia del producto y cumplimiento (χ^2 de independencia)

H_0: importancia y cumplimiento son independientes vs. H_1: están asociados

Supuestos. Cada envío ocupa una sola celda de la tabla 3 × 2 y la frecuencia esperada mínima es 382, muy superior a 5.

Resultado. El porcentaje fuera de plazo es 65,0 % en importancia alta, frente a 59,3 % en baja y 59,0 % en media (χ^2 = 12,21; gl = 2; p = 0,0022): **se rechaza H_0**, aunque la asociación es muy débil (V de Cramér = 0,033). Frente al resto, la importancia alta tiene un riesgo relativo de 1,10 y una razón de odds de 1,28 (IC 95 % [1,11; 1,47]). **Sensibilidad:** en ID > 3.135 la dirección se mantiene, pero el contraste global de las tres categorías da p = 0,059 (V = 0,027) y no se rechaza H_0 al 5 %, lo que no demuestra igualdad de tasas.

Contraste complementario. La prueba z de dos proporciones compara importancia alta con baja y media agrupadas (Wasserman, 2004). La diferencia es de 5,81 puntos porcentuales en el conjunto completo (IC 95 % [2,63; 9,00]; z = 3,49; p < 0,001) y de 4,31 puntos en ID > 3.135 (47,55 % frente a 43,24 %; IC 95 % [0,25; 8,36]; z = 2,10; p = 0,036). Las decisiones difieren porque χ^2 evalúa la igualdad global de tres tasas (2 gl) y z concentra la evidencia en un contraste de 1 gl, elegido tras la descriptiva y, por tanto, exploratorio. Para el medio de transporte no se detectó evidencia de asociación (χ^2 = 0,74; p = 0,690; V = 0,008). **Implicancia:** la mayor tasa de retraso en importancia alta no revela la política de prioridad de la empresa ni establece causalidad; requiere validación antes de orientar intervenciones.

4.3 Análisis de sensibilidad consolidado

La Tabla 6 compara los contrastes en el conjunto completo y en ID > 3.135. Mantener significancia y dirección en esta comparación exploratoria no demuestra robustez general, ni la falta de significancia demuestra ausencia de asociación.

Tabla 6. Contrastes en el dataset completo y en el subconjunto de sensibilidad.

Contraste	Efecto completo	p	Efecto ID > 3.135	p	Clasificación
Descuento (t de Welch)	d = 0,882	< 0,001	d = −0,021	0,363	Sensible: cambia la decisión
Peso (t de Welch)	d = −0,569	< 0,001	d = −0,042	0,065	Sensible: cambia la decisión
Costo (t de Welch)	d = −0,150	< 0,001	d = 0,065	0,004	Sensible: invierte el signo
Llamadas (t de Welch)	d = −0,137	< 0,001	d = 0,057	0,013	Sensible: invierte el signo
Importancia (χ^2)	V = 0,033	0,002	V = 0,027	0,059	Sensible: cambia la decisión
Medio de transporte (χ^2)	V = 0,008	0,690	V = 0,010	0,650	No significativo en ambos
Bloque de almacén (χ^2)	V = 0,010	0,896	V = 0,014	0,819	No significativo en ambos
Importancia alta vs. resto (z)	Δ = 5,81 pp	< 0,001	Δ = 4,31 pp	0,036	Mantiene significancia y dirección

Fuente: notebook §4.4 · resultados/tablas/tab16_sensibilidad_pruebas.csv. d: diferencia estandarizada (fuera de plazo menos a tiempo); V: V de Cramér; Δ: diferencia de tasas, alta menos resto; pp: puntos porcentuales. Valores p sin ajuste por multiplicidad.

Varias asociaciones dependen de la composición del archivo. Las diferencias de descuento y peso se atenúan y no alcanzan significancia en el subconjunto. El costo y las llamadas conservan significancia, pero **invierten el signo** con efectos pequeños (|d| < 0,07), un efecto de agregación (paradoja de Simpson; Simpson, 1951): el bloque inicial reúne el 40,6 % de los envíos con dos llamadas y el 2,4 % de los envíos con siete, por lo que el porcentaje fuera de plazo baja de 65,2 % a 51,6 % en el conjunto completo, pero sube de 41,4 % a 50,4 % en ID > 3.135 (figura 10 del notebook). En importancia, solo el contraste alta/resto conserva dirección y significancia nominal (p = 0,036); es una señal exploratoria, no una asociación validada.

5. Informe de avance del proyecto

Problema. La empresa debe decidir dónde concentrar recursos logísticos para reducir los envíos fuera de plazo, en un contexto en que la entrega es determinante para la satisfacción del cliente (Flórez Oviedo y López Hincapié, 2023). La decisión es bajo incertidumbre: solo se observa una muestra, de origen poco documentado.

Métodos. Descriptiva por tipo de variable, Spearman y tasas por categoría; IC normales (TCL y Wald); Welch, χ^2 y z de dos proporciones (α = 0,05) con tamaños del efecto; sensibilidad exploratoria en ID > 3.135.

Resultados e interpretación preliminar. La proporción observada fuera de plazo es 59,67 % (intervalo de Wald al 95 %: [58,75 %; 60,59 %]). El peso, el costo, el descuento y las llamadas muestran asociaciones que cambian al excluir el bloque inicial; solo la mayor tasa de retraso de los productos de importancia alta conserva dirección y significancia nominal, como señal exploratoria. Por ello, **ninguna variable justifica por sí sola una intervención logística**. Antes de usar el descuento, las llamadas o la calificación como predictores debe confirmarse que se registraron antes de la entrega.

Próximos pasos.

- **S2 · Validación:** bootstrap (≥ 10.000 remuestras; IC percentil y BCa) de los intervalos de la Tabla 5, donde se esperan discrepancias en descuento y peso; permutación (≥ 10.000) de las pruebas 1 y 2 y del contraste z en ambos conjuntos; IC bootstrap de las correlaciones de Spearman. Remuestrear el mismo archivo no corrige su representatividad.
- **S2 · Simulación y robustez:** Monte Carlo con los parámetros estimados y tratamiento del bloque inicial como subpoblación influyente.
- **S3 · Modelamiento:** como no hay faltantes, la imputación por regresión requerirá inducirlos de forma controlada (MCAR/MAR); en la regresión logística, el descuento producirá separación casi perfecta si no se trata.

6. Notebook y repositorio GitHub

El análisis se realizó en Python 3.13 con pandas (McKinney, 2010), NumPy, SciPy (Virtanen et al., 2020) y Matplotlib. El cuaderno notebooks/s1-ecommerce-analisis.ipynb sigue el orden de este informe, se ejecuta de principio a fin sin errores, fija la semilla 42 y exporta cada tabla y figura a resultados/; cada pie de este informe indica la sección del notebook y el archivo de origen. Las versiones están en requirements.txt y las decisiones metodológicas, en documentacion/decisiones-metodologicas.md. Los enlaces apuntan a la versión evaluada del repositorio.

7. Bibliografía

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum Associates.

Flórez Oviedo, N. E. y López Hincapié, E. (2023). Evolución de la logística de la última milla. Revisión de la literatura. *Ingeniería Industrial, 44*(2), 1–14.

McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

National Institute of Standards and Technology. (s. f.-a). *Measures of location*. https://www.itl.nist.gov/div898/handbook/eda/section3/eda351.htm

National Institute of Standards and Technology. (s. f.-b). *Measures of scale*. https://www.itl.nist.gov/div898/handbook/eda/section3/eda356.htm

Prachi13. (s. f.). *E-Commerce Shipping Data* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/prachi13/customer-analytics

Simpson, E. H. (1951). The interpretation of interaction in contingency tables. *Journal of the Royal Statistical Society: Series B, 13*(2), 238–241. https://doi.org/10.1111/j.2517-6161.1951.tb00088.x

Stevens, S. S. (1946). On the theory of scales of measurement. *Science, 103*(2684), 677–680. https://doi.org/10.1126/science.103.2684.677

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Wasserman, L. (2004). *All of statistics: A concise course in statistical inference*. Springer.

Wasserstein, R. L. y Lazar, N. A. (2016). The ASA statement on p-values: Context, process, and purpose. *The American Statistician, 70*(2), 129–133. https://doi.org/10.1080/00031305.2016.1154108

Welch, B. L. (1947). The generalization of "Student's" problem when several different population variances are involved. *Biometrika, 34*(1–2), 28–35. https://doi.org/10.1093/biomet/34.1-2.28

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association, 22*(158), 209–212. https://doi.org/10.1080/01621459.1927.10502953