MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 2

Validación, Simulación y Métodos de Remuestreo

Informe técnico grupal · 20 %

Título del proyecto:	Incumplimiento de plazos en envíos de comercio electrónico
Grupo:	6
Integrantes:	Marco Álvarez Araya · Ricardo Jaramillo
Dataset:	E-Commerce Shipping Data (Kaggle)
Docente:	Dr. Jean Paul Maidana González
Fecha:	20/10/2026
Repositorio GitHub:	github.com/RJaramilloP/mcdi501-ecommerce-grupo6

Información de la evaluación	
Fase del proyecto:	Fase 3: Desarrollo del proyecto
Modalidad:	Grupal
Ponderación:	20 % de la nota final
Entregables:	Informe PDF (máx. 7 págs.) · Notebook .ipynb · Repositorio GitHub (carpetas S1, S2 y archivo de resultados validados)
Resultado de aprendizaje:	RA2: implementar métodos computacionales de simulación y remuestreo para apoyar la toma de decisiones en escenarios complejos.
Indicadores:	ID2.1, ID2.2, ID2.3
Prerrequisito:	Sumativa 1 completada (usarán sus resultados).

Conexión con evaluaciones anteriores

Este informe **se construye sobre los resultados propios de la Sumativa 1 del Grupo 6**: parámetros e intervalos (S1, Tablas 10 y 11), pruebas de hipótesis (S1, Tablas 12, 14 y 15), correlaciones (S1, Tabla 5) y el subconjunto ID > 3.135. El notebook los lee desde S1/resultados/tablas/ y verifica que coincidan con el recálculo antes de usarlos. **Cada análisis se repite en el conjunto completo y en ID > 3.135, como sugirió el docente en la retroalimentación de S1.**

Índice

1. Validación de resultados de S1 mediante bootstrap 2
2. Validación de pruebas de hipótesis mediante permutación 3
3. Evaluación de estabilidad de correlaciones 4
4. Simulación Monte Carlo basada en parámetros de S1 4
5. Análisis de robustez 6
6. Preparación para la Sumativa 3 6
7. Bibliografía 7

1. Validación de resultados de S1 mediante bootstrap

La Sumativa 1 (S1) estimó cuatro parámetros con intervalos de confianza (IC) al 95 % basados en la aproximación normal, sobre el conjunto *E-Commerce Shipping Data* (Prachi13, s. f.): la proporción de envíos fuera de plazo (Wald) y las medias de costo, peso y descuento (teorema central del límite, TCL). Para validarlos sin ese supuesto se aplicó bootstrap no paramétrico con B = 10.000 remuestras y dos intervalos: el percentil y el BCa, que corrige el sesgo (z_0) y la asimetría (a, estimada por jackknife) de la distribución bootstrap (Efron, 1987; Efron y Tibshirani, 1993). Por indicación del docente se agregaron las medianas de peso y descuento; como referencia clásica para ellas se usó el IC exacto por estadísticos de orden, que no supone ninguna distribución. Cada intervalo se calculó en el conjunto completo y en el subconjunto ID > 3.135 definido en S1 (Tabla 1).

Tabla 1. IC al 95 %: clásico de S1 (Wald o normal; orden exacto para medianas; Wald de la proporción en ID > 3.135 calculado en S2 con la fórmula de S1), percentil y BCa (B = 10.000).

Conjunto	Parámetro	Estimación	IC clásico	IC percentil	IC BCa	z_0 / a
Completo	Proporción (%)	59,67	[58,75; 60,59]	[58,74; 60,57]	[58,74; 60,56]	−0,003 / −0,0006
	Costo medio	210,20	[209,30; 211,10]	[209,29; 211,10]	[209,30; 211,11]	0,010 / −0,0002
	Peso medio (g)	3.634,0	[3.603,5; 3.664,6]	[3.603,8; 3.663,7]	[3.604,2; 3.664,0]	0,011 / −0,0004
	Mediana del peso (g)	4.149	[4.119; 4.183]	[4.119; 4.183]	[4.119; 4.184] (BC)	0,003 / 0,0000
	Descuento medio	13,37	[13,07; 13,68]	[13,07; 13,68]	[13,08; 13,69]	0,011 / 0,0029

Conjunto	Parámetro	Estimación	IC clásico	IC percentil	IC BCa	z_0 / a
	Mediana del descuento	7	[7; 7]	[7; 7]	No definido	—
ID > 3.135	Proporción (%)	43,59	[42,50; 44,69]	[42,52; 44,67]	[42,52; 44,67]	0,006 / 0,0005
	Costo medio	215,86	[214,80; 216,91]	[214,82; 216,91]	[214,82; 216,90]	−0,010 / −0,0005
	Peso medio (g)	4.139,6	[4.104,7; 4.174,6]	[4.104,6; 4.175,0]	[4.104,2; 4.174,6]	−0,004 / −0,0017
	Mediana del peso (g)	4.657	[4.631; 4.686]	[4.631; 4.686]	[4.631; 4.686] (BC)	−0,019 / 0,0000
	Descuento medio	5,52	[5,46; 5,58]	[5,46; 5,58]	[5,46; 5,58]	0,001 / 0,0000
	Mediana del descuento	6	[5; 6]	[5; 6]	[5; 6] (BC)	0,313 / 0,0000

Fuente: notebook S2 §1.3 · S2/resultados/tablas/s2_tab01_bootstrap_ic.csv; IC clásicos: S1, Tablas 10 y 11

Medias y proporción. En los ocho intervalos los tres métodos coinciden: la razón entre la amplitud del IC percentil y la del clásico va de 0,98 a 1,01, el centro del BCa se desplaza a lo sumo 0,06 errores estándar respecto del clásico y $|z_0| \leq 0{,}011$, $|a| \leq 0{,}003$. Incluso el descuento, la variable más asimétrica de S1 (asimetría 1,80), produce una distribución bootstrap de la media casi simétrica (asimetría 0,04): con n = 10.999 el TCL compensa la asimetría de los datos (Figura 1). Los IC de S1 quedan validados. El BCa propio difiere en menos de 0,1 errores estándar del de *scipy.stats.bootstrap* (Virtanen et al., 2020).

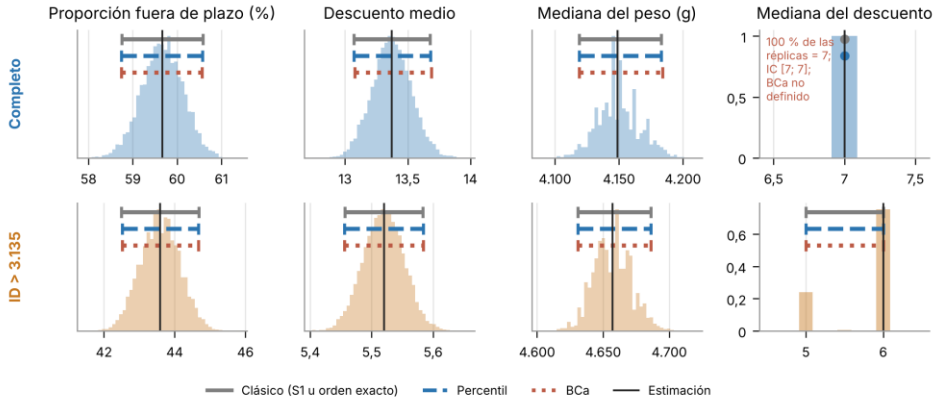


Figura 1. Distribuciones bootstrap (10.000 remuestras) de cuatro parámetros, con los IC clásico, percentil y BCa superpuestos.

Fuente: notebook S2 §1.6 · S2/resultados/figuras/s2_fig01_bootstrap_ic.png

Medianas. La mediana del peso, 4.149 g [4.119; 4.183], coincide con el intervalo por estadísticos de orden y supera en 515 g a la media porque el peso es bimodal; como el jackknife de la mediana es constante por los empates, se usa la variante BC (a = 0). En la del descuento, las 10.000 réplicas valen 7: el percentil es [7; 7] y BCa no está definido porque el estimador es discreto. Un bootstrap suavizado (Hall et al., 1989) da [6,96; 7,21] y, en ID > 3.135, [5,43; 5,65], bajo la mediana 6, porque estima la mediana de la variable continua antes del redondeo; allí la distribución bootstrap se reparte entre 6 (75,4 %) y 5 (23,9 %).

Dónde está la discrepancia. Entre conjuntos, no entre métodos: el descuento medio pasa de 13,37 a 5,52 y la mediana del peso de 4.149 a 4.657 g, sin solapamiento (sección 5).

2. Validación de pruebas de hipótesis mediante permutación

Bajo la hipótesis nula de no asociación, las etiquetas «a tiempo» y «fuera de plazo» son intercambiables: la prueba de permutación las reasigna al azar 10.000 veces y obtiene $p = (\#\{|T^*| \geq |T_{obs}|\} + 1)/(B + 1)$, sin supuestos distribucionales (Good, 2005; Ojala y Garriga, 2010). Se validaron las dos pruebas de S1 (Welch del peso y χ^2 de la importancia), el contraste z de importancia alta frente al resto y, por sugerencia del docente, la diferencia de medianas del peso (referencia clásica: prueba de la mediana; Mood, 1950). Para Welch se permutó el t estudentizado, asintóticamente válido aun con varianzas distintas (Chung y Romano, 2013). Como S1 obtuvo en el subconjunto valores p cercanos a 0,05, allí se usaron 100.000 permutaciones (Tabla 2).

Concordancia. Las ocho comparaciones coinciden con la decisión clásica y las densidades asintóticas de S1 se superponen a las distribuciones por permutación (Figura 2). En el subconjunto, Welch da p = 0,0638 (S1: 0,0645), χ^2 0,0593 (0,0595) y z 0,0357 (0,0361), con errores Monte Carlo entre 0,0006 y 0,0012.

Robustez. La permutación no altera ninguna conclusión de S1; lo que las altera es el bloque inicial. La diferencia de medianas del peso, −1.443 g en el conjunto completo, cae a −38 g en el subconjunto (p = 0,180): la desaparición del efecto del peso no depende de usar medias. El contraste z es el único nominalmente significativo en el subconjunto, pero no resiste la corrección de Holm (1979) sobre las cuatro pruebas (p ajustado = 0,143); con una familia menos

conservadora, solo las tres pruebas de S1, quedaría en 0,107. Además, los efectos del subconjunto son despreciables (d = −0,04; V = 0,027): significancia no es relevancia (Wasserstein y Lazar, 2016).

Tabla 2. Pruebas de S1 validadas por permutación (10.000 en el completo; 100.000 en ID > 3.135).

Conjunto	Prueba	Estadístico	p clásico	p permutación ± EE	p Holm	Efecto	Decisión
Completo	Peso, t de Welch	−29,27	< 0,001	< 0,001	—	d = −0,57	Concuerda
	Peso, medianas	−1.443 g	< 0,001	< 0,001	—	Δ = −1.443 g	Concuerda
	Importancia, χ^2	12,21	0,0022	0,0024 ± 0,0005	—	V = 0,033	Concuerda
	Alta vs. resto, z	3,49	< 0,001	< 0,001	—	Δ = 5,81 pp	Concuerda
ID > 3.135	Peso, t de Welch	−1,85	0,0645	0,0638 ± 0,0008	0,178	d = −0,04	Concuerda
	Peso, medianas	−38 g	0,2184	0,1804 ± 0,0012	0,180	Δ = −38 g	Concuerda
	Importancia, χ^2	5,64	0,0595	0,0593 ± 0,0007	0,178	V = 0,027	Concuerda
	Alta vs. resto, z	2,10	0,0361	0,0357 ± 0,0006	0,143	Δ = 4,31 pp	Concuerda

Fuente: notebook S2 §2.1 · S2/resultados/tablas/s2_tab02_permutacion.csv; p clásicos: S1, Tablas 12, 14 y 15

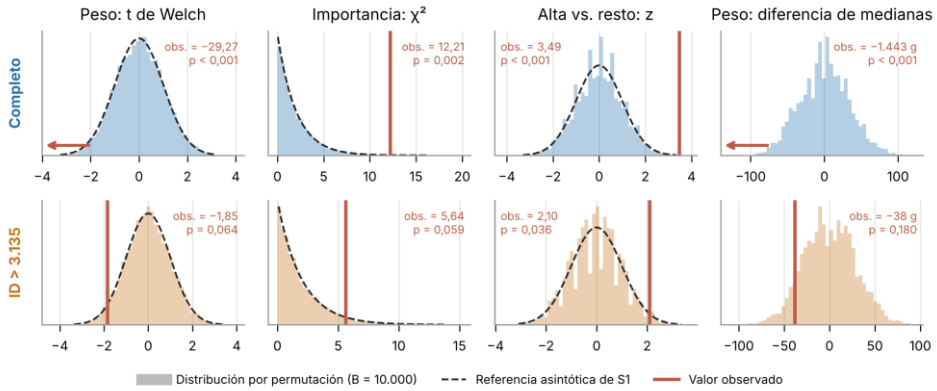


Figura 2. Distribuciones nulas por permutación con la referencia asintótica de S1 y el valor observado.
Fuente: notebook S2 §2.2 · S2/resultados/figuras/s2_fig02_permutacion.png

3. Evaluación de estabilidad de correlaciones

Se evaluaron las cinco correlaciones de Spearman con el retraso que en S1 superaron |ρ| = 0,05 (Tabla 5 de S1), con IC bootstrap percentil al 95 % (B = 10.000, reordenando en cada remuestra) en ambos conjuntos. Una correlación es **estable** si su IC excluye el 0 en los dos conjuntos con el mismo signo y conserva al menos la mitad de su magnitud; **atenuada**, si pierde más de la mitad; **dependiente del bloque**, si su IC incluye el 0 en el subconjunto; y con **inversión de signo**, si los IC excluyen el 0 con signos opuestos (Figura 3).

Ninguna correlación es estable. La del descuento, la más fuerte de S1 (0,335 [0,319; 0,351]), desaparece en ID > 3.135 (−0,010 [−0,032; 0,012]). El peso mantiene el signo, pero su magnitud cae 91 % (−0,266 → −0,023). Las compras previas pasan a 0,007, y el costo (−0,072 → 0,034) y las llamadas (−0,064 → 0,026) invierten el signo con IC que excluyen el 0: un efecto de composición análogo a la paradoja de Simpson de S1. Estos IC suponen independencia; con bootstrap por bloques de 500 envíos (sección 5), los del completo se ensanchan entre 2,5 y 9,0 veces, pero incluso con estos IC, más conservadores, siguen excluyendo el 0 (costo [−0,117; −0,015]; llamadas [−0,109; −0,013]): la inestabilidad es de composición, no de ruido muestral, y ninguna correlación justifica por sí sola incluir una variable en los modelos de S3.

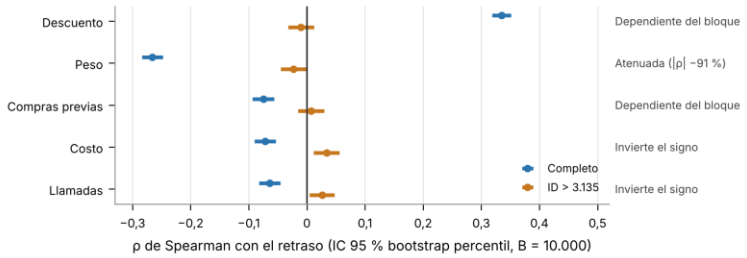


Figura 3. ρ de Spearman con el retraso e IC bootstrap al 95 % en ambos conjuntos, con la clasificación de estabilidad.
Fuente: notebook S2 §3 · S2/resultados/tablas/s2_tab03_correlaciones_bootstrap.csv · S2/resultados/figuras/s2_fig03_correlaciones.png

4. Simulación Monte Carlo basada en parámetros de S1

El IC de S1 describe la incertidumbre del parámetro, no la de un lote concreto. La simulación estima, para un lote de N envíos, la tasa de retraso, su dispersión y la probabilidad de superar lo que S1 consideró plausible. Cada envío es de

importancia alta con probabilidad w y llega fuera de plazo con probabilidad p_{alta} o p_{resto}, parámetros tomados exclusivamente de S1 (Tabla 15 de S1): w = 8,62 %, p_{alta} = 64,98 % y p_{resto} = 59,17 % en el conjunto completo; 8,05 %, 47,55 % y 43,24 % en ID > 3.135. En cada iteración los parámetros se extraen de una normal centrada en la estimación de S1 con su error estándar, para propagar la incertidumbre de la estimación (Robert y Casella, 2004). Umbral de alerta: límite superior del IC de Wald de S1 (60,59 %); base: N = 1.000, 10.000 lotes, semilla 42.

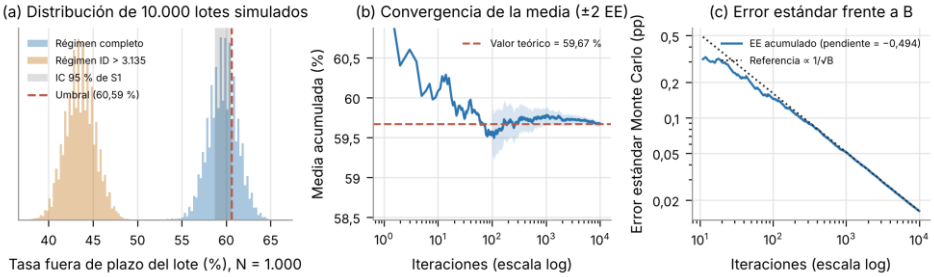


Figura 4. Monte Carlo de un lote de 1.000 envíos: distribución por régimen, convergencia de la media y error estándar frente a B.

Fuente: notebook S2 §4.1–4.2 · S2/resultados/figuras/s2_fig04_montecarlo.png

Convergencia (Figura 4). La media simulada (59,67 % ± 0,016 pp) está a 0,2 errores estándar del valor teórico $w \cdot p_{alta} + (1 - w) \cdot p_{resto}$, igual a la proporción de S1, y el error estándar decrece con pendiente −0,494 (teórica: −0,5). Las cantidades de decisión también convergen: P(lote > umbral) = 0,295 ± 0,005 (de 0,286 a 0,301 en cinco semillas) y P99 = 63,3 % ± 0,06 pp. Geweke (1992) rechaza solo en la semilla base (1 de 5), lo esperable por azar con iteraciones independientes.

Parámetro frente a lote. Frente al IC de S1 [58,75; 60,59] %, un lote varía en [56,5; 62,8] % (central 95 %) y 29,5 % de los lotes supera el umbral sin que el proceso cambie; los parámetros explican 8,3 % de la varianza del lote (igual por simulación y por método delta) y el resto es variabilidad binomial: un lote con 61–62 % de retrasos no indica deterioro.

Escenarios y sensibilidad (Tabla 3 y Figura 5). El P99, útil como umbral de alerta, baja de 71,0 % con N = 100 a 61,6 % con N = 5.000. Con los parámetros del subconjunto la tasa esperada es 43,6 %: la distancia entre regímenes es unas 10 desviaciones estándar de un lote. El tornado confirma que el régimen y la tasa del resto dominan; la tasa de la importancia alta tiene un efecto intermedio y su proporción, uno mínimo. Con los mismos lotes, si la importancia alta tuviera la tasa del resto, se evitarían 4,9 retrasos por cada 1.000 envíos [1; 11]: un ejercicio hipotético, no causal, que acota en un nivel bajo el beneficio de priorizar ese segmento.

Tabla 3. Escenarios Monte Carlo (10.000 lotes por escenario; mismos números aleatorios entre escenarios con igual N).

Escenario	Tasa media	DE (pp)	Central 95 % (%)	P99	P(> umbral)	Evitados por 1.000
Completo, N = 100	59,72 %	4,91	[50,0; 69,0]	71,0 %	0,441	—
Completo, N = 1.000 (base)	59,67 %	1,62	[56,5; 62,8]	63,3 %	0,295	—
Completo, N = 5.000	59,68 %	0,83	[58,1; 61,3]	61,6 %	0,135	—
Régimen ID > 3.135, N = 1.000	43,59 %	1,67	[40,4; 46,9]	47,5 %	0,000	—
Doble de importancia alta	60,17 %	1,62	[57,0; 63,3]	63,8 %	0,412	—
Alta con la tasa del resto	59,18 %	1,63	[56,0; 62,4]	62,9 %	0,201	4,9 [1; 11]
Ídem, régimen ID > 3.135	43,25 %	1,68	[40,0; 46,6]	47,1 %	0,000	3,4 [0; 9]

Fuente: notebook S2 §4.3 · S2/resultados/tablas/s2_tab04d_escenarios.csv

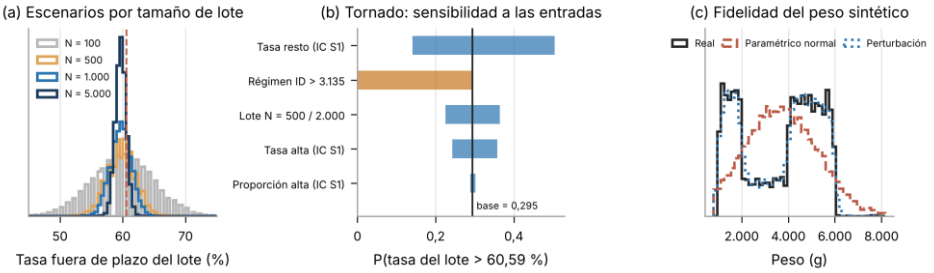


Figura 5. Escenarios por tamaño de lote, diagrama de tornado y fidelidad del peso en los datos sintéticos.

Fuente: notebook S2 §4.3–4.5 · s2_tab04h_tornado.csv · s2_tab04f_fidelidad_peso.csv · S2/resultados/figuras/s2_fig05_escenarios_sensibilidad.png

Datos sintéticos. Que las tasas reales caigan dentro del intervalo central de 10.000 archivos sintéticos solo verifica la implementación, porque son los parámetros del generador. La fidelidad se probó con el peso: un generador normal

con la media y la desviación de S1 no reproduce la bimodalidad (KS D = 0,135; 43,0 % de envíos entre 2.000 y 3.999 g frente a 16,3 % reales), a diferencia de la perturbación de valores reales (D = 0,019). Con el generador se estimó la potencia del contraste z: con n = 7.864, la de detectar 4 pp es 49 % y harían falta unos 14.000 envíos para 80 % ante la diferencia de S1; no se usa la potencia observada, que solo reexpresa el valor p (Hoenig y Heisey, 2001). Bajo H_0 el rechazo fue 4,97 %. La cobertura en 2.000 muestras sintéticas muestra que con n = 30 el BCa se acerca más al nominal que el IC clásico (proporción: clásico 93,5 % frente a BCa 95,8 %; media del descuento: clásico 91,6 % frente a BCa 94,5 %), mientras que con muestras grandes los tres métodos se acercan al 95 %: la coincidencia de la sección 1 es la esperada.

5. Análisis de robustez

Se evaluaron tres amenazas: valores atípicos (media recortada al 5 %, media sin el 1 % superior, mediana y jackknife); el supuesto de independencia, con bootstrap de bloques móviles circulares de 1 a 500 envíos, que conserva la dependencia entre envíos consecutivos (Künsch, 1989; Politis y Romano, 1992); y el corte post hoc de S1, repitiendo el análisis para cortes entre 0 y 6.000 (Figura 6). La normalidad del TCL quedó validada en la sección 1.

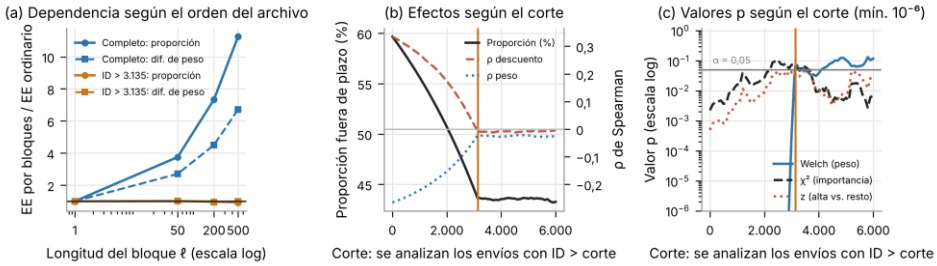


Figura 6. Razón de errores estándar por bloques, efectos y valores p según el corte del subconjunto.
Fuente: notebook S2 §5.2–5.3 · S2/resultados/tablas/s2_tab05c_barrido_corte.csv · S2/resultados/figuras/s2_fig06_robustez.png

Atípicos. Costo y peso son estables frente a recortes (cambios ≤ 1,7 %). El descuento medio del conjunto completo cae 14,1 % al recortar el 5 % extremo, por sus 2.209 atípicos concentrados en el bloque inicial; en el subconjunto no hay atípicos del descuento, y los 1.906 del peso son su modo inferior, no errores. La diferencia de peso se sostiene con estimadores robustos en el completo (media −896 g; recortada −992 g; mediana −1.443 g) y desaparece con cualquiera de ellos en el subconjunto (−67; −74; −38 g). Ningún envío mueve una media más de 0,03 errores estándar: la influencia es **de grupo**, no de casos aislados.

Independencia. Es el hallazgo nuevo más relevante. En el conjunto completo, el error estándar de la proporción crece 3,7, 7,3 y 11,3 veces con bloques de 50, 200 y 500 envíos, y el de la diferencia de peso, 6,7 veces; en el subconjunto las razones quedan entre 0,92 y 1,03. Los envíos cercanos en el ID comparten régimen. La razón no se estabiliza al crecer el bloque, señal de un quiebre en la serie y no de dependencia estacionaria: es un diagnóstico de estructura por orden, no un error estándar corregido. Los IC de S1 del completo valen solo bajo independencia, plausible en el subconjunto, igual que la independencia que supone el Monte Carlo.

Corte post hoc. En los 30 cortes iguales o mayores a 3.135, la proporción (43,2–43,7 %), la diferencia de peso (−84 a −65 g) y las correlaciones permanecen prácticamente constantes, mientras que bajo 3.135 derivan a medida que entran envíos del bloque: el corte coincide con el punto donde los efectos se estabilizan. Welch es significativo solo en 23 % de esos cortes; χ^2 y z, en 83 % y 97 %, aunque oscilan en torno a 0,05 en el corte de S1: la señal de la importancia es frágil, no ausente.

6. Preparación para la Sumativa 3

El notebook genera el reporte de resultados validados como archivo separado (resultados_validados.md y resultados_validados.csv) con 16 resultados. Cada uno se clasifica con una regla única en dos dimensiones: *coherente entre métodos* (los métodos de S2 confirman el resultado de S1) y *estable entre conjuntos* (cambio < 5 %, misma decisión con Holm o correlación estable). Es **robusto** si cumple ambas; **señal exploratoria** si no es estable, pero mantiene la dirección del efecto y es significativa en la mayoría de los cortes ≥ 3.135; y **dependiente del bloque** en otro caso (Tabla 4).

Tabla 4. Resumen del reporte de resultados validados.

Resultado de S1	Evidencia en S2	Estado
Costo medio	IC coinciden en los tres métodos; 2,7 % en ID > 3.135	Robusto
Proporción; peso y descuento (medias y medianas)	IC coinciden entre métodos; cambian entre 12 % y 59 % en ID > 3.135	Dependiente del bloque
Welch y diferencia de medianas del peso	Permutación concuerda; el efecto desaparece en ID > 3.135	Dependiente del bloque
ρ descuento y compras previas	IC incluye el 0 en ID > 3.135	Dependiente del bloque
ρ peso	Mismo signo; |ρ| −91 % en ID > 3.135	Dependiente del bloque
ρ costo y llamadas	Cambian de signo entre conjuntos, también con IC por bloques	Dependiente del bloque
χ^2 importancia; z alta vs. resto	Misma dirección; Holm p ≥ 0,14; p < 0,05 en ≥ 83 % de los cortes	Señal exploratoria
Lote de 1.000 envíos (Monte Carlo)	Convergido; tasa 59,7 % o 43,6 % según el régimen	Dependiente del bloque

Fuente: notebook S2 §6 · S2/resultados_validados.csv

Observaciones influyentes. El bloque ID ≤ 3.135 (3.135 envíos, todos fuera de plazo, que incluyen los 2.647 con descuento mayor a 10); ningún envío aislado es influyente por sí solo.

Recomendaciones metodológicas para S3:

- Modelar en ID > 3.135 y repetir en el completo con un indicador del bloque; validar con bloques contiguos de ID.
- No incluir el descuento sin tratamiento (separación casi perfecta en el completo; ρ = −0,010 en el subconjunto); si se incluye, usar la regresión penalizada de Firth (1993).
- Confirmar qué variables existen antes de la entrega (descuento, llamadas, calificación) para evitar fuga de información.
- Tratar la importancia alta como exploratoria (potencia de 49 % para 4 pp) y costo y llamadas solo dentro de un régimen.
- Imputar el peso con PMM o residuos empíricos (van Buuren y Groothuis-Oudshoorn, 2011), no con un supuesto normal.
- Comparar con la clase mayoritaria (59,7 % y 56,4 % «a tiempo» en el subconjunto), reportar AUC, recall y precisión, y aplicar Holm.

El notebook se ejecuta completo con semilla 42 y verifica los parámetros de S1 contra el recálculo antes de usarlos; las tablas y figuras citadas están en S2/resultados.

7. Bibliografía

Chung, E. y Romano, J. P. (2013). Exact and asymptotically robust permutation tests. *The Annals of Statistics, 41*(2), 484–507. https://doi.org/10.1214/13-AOS1090

Efron, B. (1987). Better bootstrap confidence intervals. *Journal of the American Statistical Association, 82*(397), 171–185. https://doi.org/10.1080/01621459.1987.10478410

Efron, B. y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall/CRC. https://doi.org/10.1201/9780429246593

Firth, D. (1993). Bias reduction of maximum likelihood estimates. *Biometrika, 80*(1), 27–38. https://doi.org/10.1093/biomet/80.1.27

Geweke, J. (1992). Evaluating the accuracy of sampling-based approaches to the calculation of posterior moments. En J. M. Bernardo, J. O. Berger, A. P. Dawid y A. F. M. Smith (Eds.), *Bayesian statistics 4* (pp. 169–193). Oxford University Press.

Good, P. I. (2005). *Permutation, parametric, and bootstrap tests of hypotheses* (3.ª ed.). Springer. https://doi.org/10.1007/b138696

Hall, P., DiCiccio, T. J. y Romano, J. P. (1989). On smoothing and the bootstrap. *The Annals of Statistics, 17*(2), 692–704. https://doi.org/10.1214/aos/1176347135

Hoenig, J. M. y Heisey, D. M. (2001). The abuse of power: The pervasive fallacy of power calculations for data analysis. *The American Statistician, 55*(1), 19–24. https://doi.org/10.1198/000313001300339897

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics, 17*(3), 1217–1241. https://doi.org/10.1214/aos/1176347265

Mood, A. M. (1950). *Introduction to the theory of statistics*. McGraw-Hill.

Ojala, M. y Garriga, G. C. (2010). Permutation tests for studying classifier performance. *Journal of Machine Learning Research, 11*, 1833–1863.

Politis, D. N. y Romano, J. P. (1992). A circular block-resampling procedure for stationary data. En R. LePage y L. Billard (Eds.), *Exploring the limits of bootstrap* (pp. 263–270). Wiley.

Prachi13. (s. f.). *E-Commerce Shipping Data* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/prachi13/customer-analytics

Robert, C. P. y Casella, G. (2004). *Monte Carlo statistical methods* (2.ª ed.). Springer. https://doi.org/10.1007/978-1-4757-4145-2

van Buuren, S. y Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software, 45*(3), 1–67. https://doi.org/10.18637/jss.v045.i03

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Wasserstein, R. L. y Lazar, N. A. (2016). The ASA statement on p-values: Context, process, and purpose. *The American Statistician, 70*(2), 129–133. https://doi.org/10.1080/00031305.2016.1154108